

计算机保研面试_数学常见题

计算机保研面试_数学常见题

1 线性代数

- (1) 余子式
- (2) 行列式
- (3) 矩阵的秩, 满秩, 不满秩
- (4) 矩阵的迹
- (5) 线性方程组解的情况
- (6) 线性相关, 线性无关
- (7) 方阵可逆的充要条件
- (8) 向量空间, 线性空间
- (9) 向量空间的基和维数
- (10) 矩阵的特征值和特征向量
- (11) 向量正交, 矩阵正交
- (12) 正交矩阵
- (13) 相似矩阵
- (14) 合同矩阵
- (15) 正定矩阵
- (16) 范数
- (17) 内积
- (18) 特征值分解
- (19) 奇异值分解

2 概率论

- (1) 全概率公式和贝叶斯公式
- (2) 大数定律
- (3) 中心极限定理
- (4) 变量与随机变量有什么区别?
- (5) 联合概率、边缘概率、条件概率
- (6) 先验概率、后验概率
- (7) 常见的概率分布
- (8) 若干个高斯分布相加/相乘后得到的分布是什么
- (9) 期望和方差
- (10) 协方差和相关系数
- (11) 独立和不相关的区别
- (12) 独立和互斥的关系
- (13) 古典概型和几何概型的区别
- (14) 概率密度函数
- (15) 极大似然估计
- (16) 什么是假设和检验
- (17) 机器学习为什么要使用概率?
- (18) 不均匀硬币产生等概率
- (19) 伪随机数产生均匀分布
- (20) 由均匀分布产生高斯分布

3 微积分

4 离散数学

- (1) 自反、对称、传递
- (2) 对称传递能不能推出自反性?
- (3) 自反性存在有什么意义?
- (4) 等价关系和等价类
- (5) 偏序关系

1 线性代数

(1) 余子式

- 余子式：n 阶行列式中，划去 a_{ij} 所在的第 i 行与第 j 列的元，剩下的元所构成的 $n-1$ 阶行列式称为 a_{ij} 的余子式。
- 代数余子式：在余子式前面乘上 $(-1)^{i+j}$

(2) 行列式

- 行列式 $\det(A)$ ，是一个将方阵 A 映射到实数的函数。
- 几何意义：行列式是有向面积或体积的概念在欧几里得空间中的推广，它描述了一个线性变换对“体积”的影响。
 - 2 阶行列式代表的是平面内的面积。
 - 3 阶行列式代表的是立体空间内的体积。
 - 4 阶行列式是 4 维空间里的超体积。
- 计算方法：行列式等于它任意一行（列）的各元素与其对应的代数余子式乘积之和。
- 行列式和矩阵特征值的关系：行列式等于矩阵特征值的乘积。

(3) 矩阵的秩，满秩，不满秩

- 矩阵的秩
 - 子式角度：矩阵的非零子式的最高阶数。

k 阶子式：在矩阵中取 k 行 k 列，交叉处的 k^2 个元素按原顺序构成的行列式。
 - 线性无关角度：矩阵的所有行向量中极大线性无关组的元素个数。
 - 标准型角度：先将矩阵转化为行阶梯型，其非零行个数就是矩阵的秩。
- 满秩：一个秩为 n 的矩阵满秩意味着存在一个 n 阶子式不为 0。
- 不满秩：假设其秩为 r ，意味着存在一个 r 阶子式不为 0，其所有阶数大于 r 的子式都为 0。

(4) 矩阵的迹

方阵 A 的迹：对角线元素之和。

(5) 线性方程组解的情况

- 齐次线性方程组 $AX = 0$: $r(A) = n$, 有惟一零解; $r(A) < n$, 有无穷多解。
- 非齐次线性方程组 $AX = b$: $r(A) \neq r([A, b])$, 无解; $r(A) = r([A, b]) = n$, 有唯一解; $r(A) = r([A, b]) < n$, 有无穷多解。

(6) 线性相关, 线性无关

- 对于线性空间中的 n 个向量, 若存在 n 个不全为 0 的常数, 使得这 n 个常数与 n 个向量对应乘积加和等于 0, 则称这 n 个向量线性相关, 如果不存在这样的 n 个常数, 称之为线性无关。
- 几何意义: n 个向量线性无关等价于他们所张成的 n 维体的体积不为 0; 若线性相关, 则体积为 0。

(7) 方阵可逆的充要条件

1. 方阵 A 可逆。
2. A 是非奇异矩阵 ($|A| \neq 0$) 。
3. A 满秩。
4. A 可以表示成有限个初等矩阵的乘积。
5. 特征值没有 0。
6. 矩阵线性无关。

(8) 向量空间, 线性空间

- 向量空间: 所有 n 维向量构成的集合称为 n 维向量空间。
- 线性空间: 若非空集合 V 上满足加法封闭性和乘法封闭性, 并且还满足以下 8 条性质: 加法交换律、加法结合律、加法零元、加法逆元、数乘幺元、数乘结合律、数乘分配律 (2个), 则称集合 V 是线性空间。
- 两者的关系: 线性空间包含向量空间, 除了向量空间, 线性空间还包括多项式空间、矩阵空间等。

(9) 向量空间的基和维数

- 基: 在向量空间 V 中可以找到 n 个向量, 这 n 个向量线性无关, 并且线性空间 V 中的任意一个向量都和这 n 个向量线性相关, 那么这 n 个向量就称作线性空间 V 的一个基。
- 维数: 基中所含向量个数。

(10) 矩阵的特征值和特征向量

- 含义: 矩阵就是一个线性变换, 它作用于特征向量后, 向量方向保持不变 (不发生旋转变换), 进行某一比例的伸缩变换, 这个比例就是特征值, 即

$$AX = \lambda X, \text{ 其中 } X \text{ 是 } A \text{ 的特征向量, } \lambda \text{ 是 } A \text{ 的特征值}$$

- 特征值和特征向量的关系
 - 特征值和特征向量是一对多的关系，一个特征值可能对应多个特征向量，一个特征向量只能属于一个特征值。
 - 属于不同特征值的特征向量一定线性无关。
 - 设 λ 是 n 阶方阵 A 的一个 k 重特征值 (λ 为特征方程的 k 重根)，对应于 λ 的线性无关的特征向量的最大个数为 l ，则 $k \geq l$ ，即特征值 λ 的**代数重数不小于几何重数**。
- 应用：奇异值分解、主成分分析。

(11) 向量正交，矩阵正交

- 向量正交：在正交向量组中，任意两个向量的数量积为 0。
- 矩阵正交：两个矩阵正交，表示这两个矩阵相乘结果为单位矩阵。

(12) 正交矩阵

A 是正交矩阵 $\iff A^T A = E \iff A^T = A^{-1} \iff A$ 的各列向量是标准正交向量组（都是单位向量，且两两正交）。

(13) 相似矩阵

- 相似矩阵：对于两个矩阵 A, B ，如果存在一个可逆矩阵 P ，使得矩阵 $P^{-1}AP = B$ ，那么矩阵 A 相似于矩阵 B 。
- 意义：相似的矩阵是同一个线性变换在不同基/坐标系下的不同描述。
- 性质：两个相似的矩阵具有相同的秩、迹、行列式、特征值，但特征向量未必相同。
- 补充：实对称矩阵有相同的特征值则必相似。

因为实对称矩阵可对角化，对角化后对角上就是特征值。

(14) 合同矩阵

设 A, B 是两个方阵，若存在可逆矩阵 C ，使得 $C^T A C = B$ ，则称方阵 A, B 合同，记作 $A \simeq B$ 。

(15) 正定矩阵

- 正定矩阵：假设一个实对称矩阵 A ，对于任意一个非零的列向量 S ，都有 $S^T A S > 0$ ，则该矩阵正定。
- 半正定矩阵：就是把上面的 $>$ 改成 $\geq$
- 性质：
 - 特征值全为正。
 - 各阶主子式大于零。

- 对称矩阵 A 正定的充要条件： A 的特征值全为正。

(16) 范数

- R^n 上的**向量** $x = (x_1, \dots, x_n)^T$ 的范式（离散型范数公式）：

$$\|x\|_{\infty} = \max_{1 \leq i \leq n} |x_i|$$

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

$$\|x\|_2 = \left(\sum_{i=1}^n x_i^2\right)^{\frac{1}{2}}$$

带权重的形式（以2-范数为例）： $\|x\|_2 = \left(\sum_{i=1}^n w_i x_i^2\right)^{\frac{1}{2}}$

- $C[a, b]$ 上的**函数** $f(x)$ 的范式（连续型范数公式）：

$$\|f\|_{\infty} = \max_{a \leq x \leq b} |f(x)|$$

$$\|f\|_1 = \int_a^b |f(x)| dx$$

$$\|f\|_2 = \left(\int_a^b f^2(x) dx\right)^{\frac{1}{2}}$$

带权重的形式（以2-范数为例）： $\|f(x)\|_2 = \left(\int_a^b \rho(x) f^2(x) dx\right)^{\frac{1}{2}}$

- $R^{n \times n}$ 上的**矩阵** A 的范式：

$$\text{行范式} : \|A\|_{\infty} = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|$$

$$\text{列范式} : \|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|$$

$$\text{谱范式} : \|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}, \text{其中 } \lambda_{\max} \text{ 表示最大特征值}$$

$$F \text{ 范式} : \|A\|_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n a_{ij}^2}$$

$A = \begin{bmatrix} 4 & -3 \\ -1 & 6 \end{bmatrix}$ 的范式:

$$\text{行范式} : \|A\|_{\infty} = \max \{ \text{各行绝对值之和} \} = \max \{ 7, 7 \} = 7$$

$$\text{列范式} : \|A\|_1 = \max \{ \text{各列绝对值之和} \} = \max \{ 5, 9 \} = 9$$

$$F \text{ 范式} : \|A\|_F = \sqrt{4^2 + 3^2 + 1^2 + 6^2} = 7.87401$$

$$\text{谱范式} : \|A\|_2 = \sqrt{\lambda_{\max} \left(\begin{bmatrix} 17 & -18 \\ -18 & 45 \end{bmatrix} \right)} = 7.335087491$$

怎么求矩阵 A 的最大特征值？ $|\lambda E - A| = 0$ ，然后求 λ 的最大解

(17) 内积

- R^n 上的**向量** x, y 的内积（离散型内积公式）：

$$(x, y) = \sum_{i=1}^n w_i x_i y_i$$

w_i 是权重

- $C[a, b]$ 上的**函数** $f(x), g(x)$ 的内积（连续型内积公式）：

$$(f(x), g(x)) = \int_a^b \rho(x) f(x) g(x) dx$$

$\rho(x)$ 是权函数, 一般为 $1, \frac{1}{\sqrt{1-x^2}}, \sqrt{1-x^2}$

(18) 特征值分解

- 特征值分解 (谱分解): 对于一个方阵 A , $\lambda_1 \leq \dots \leq \lambda_n$ 是 A 的 n 个特征值, w_1, w_2, w_n 是其对应的 n 个线性无关的特征向量, 则存在正交矩阵 W , 使得

$$W^{-1}AW = W^TAW = \Lambda = \begin{pmatrix} \lambda_1 & & \\ & \dots & \\ & & \lambda_n \end{pmatrix}$$

其中 W 是将 A 的 n 个特征向量单位化后组成的 $n \times n$ 矩阵。

- 意义: 将一个方阵对应的线性变换转化为“旋转——拉伸——旋转”变换。

正交矩阵对应旋转变换, 对角矩阵对应拉伸变换。

(19) 奇异值分解

奇异值分解 (SVD): 特征值分解的扩展, 适用于任意矩阵 $A_{m \times n}$ 。

$$A = U\Sigma V^T$$

- $U_{m \times m}$: 对称矩阵, 由 AA^T 的所有特征向量组成, 其中每个特征向量叫做 A 的左奇异向量。
- $V_{n \times n}$: 对称矩阵, 由 A^TA 的所有特征向量组成, 其中每个特征向量叫做 A 的右奇异向量。
- $\Sigma_{m \times n}$: 除了对角线上是奇异值, 其他全为 0, 奇异值 σ_i 由 $Av_i = \sigma_i u_i$ 求得。

2 概率论

(1) 全概率公式和贝叶斯公式

- 全概率公式
 - 由因推果。造成某种结果, 有多种原因, 求发生这种结果的概率是多少?
 - 假设造成结果 A 的原因有 $B_1, B_2, \dots, B_n$, 则 A 发生的概率为每个原因发生的概率乘以在这种情况下 A 发生的条件概率的加和, 即

$$p(A) = \sum_{i=1}^n p(B_i)p(A|B_i)$$

- 贝叶斯公式
 - 由果推因。已知某结果的发生概率, 求造成该结果的第 i 个原因的概率是多少?
 - 假设结果 A 发生的概率为 $p(A)$, 原因可能有 $B_1, B_2, \dots, B_n$, 则 A 是由 B_i 造成的概率 $p(B_i|A)$ 这样求

先用条件概率公式计算，再用全概率公式替换分母

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(B_j)P(A|B_j)}$$

(2) 大数定律

- 大数定律：当重复试验的次数很大时，随机变量的**均值**依概率收敛于自己的**期望**，“偶然中包含着某种必然”。
- 意义：大数定律将数理统计中的均值和概率论中的期望联系在了一起。
- 三种表述
 - 切比雪夫大数定律：随机变量 $X_1, X_2, \dots, X_n$ 独立、期望 EX_i 和方差 DX_i 都存在、方差 DX_i 有一致上界（即每个方差都有上界且收敛速度接近），则**样本均值收敛于自己的期望**，即

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \frac{1}{n} \sum_{i=1}^n EX_i$$

- 伯努利大数定律：对于 $X \sim B(n, p)$ ，当 n 很大时，有 $\frac{X}{n} \xrightarrow{P} p$ 。即大量独立重复实验后，随机事件发生的**频率收敛于概率**。
- 辛钦大数定律：随机变量 $X_1, X_2, \dots, X_n$ 独立同分布、期望 $EX = \mu$ 存在，当 n 很大时，他们的**算术平均值依概率收敛于期望**，即

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

(3) 中心极限定理

- 独立同分布中心极限定理：随机变量 $X_1, X_2, \dots, X_n$ 独立同分布，期望 $EX = \mu$ ，方差 $DX = \sigma^2 > 0$ ，当 n 很大时，则均值 $\bar{X}_n$ 近似服从正态分布 $N(\mu, \sigma^2/n)$ ，即

$$\lim_{n \rightarrow \infty} P\left(\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} < a\right) = \Phi(a) = \int_{-\infty}^a \frac{1}{\sqrt{2\pi}} e^{-t^2/2} dt$$

- 拉普拉斯 / 二项分布中心极限定理：是独立同分布中心极限定理的特殊情况，设随机变量 ξ_n 服从二项分布 $B(n, p)$ ， ξ_n 可视为 n 个独立同分布的 0-1 分布随机变量的和，当 n 很大时，则均值 ξ_n 近似服从正态分布 $N(np, np(1-p))$ ，即

$$\lim_{n \rightarrow \infty} P\left(\frac{\xi_n - np}{\sqrt{np(1-p)}} < a\right) = \Phi(a)$$

该定理表明：当试验次数 n 足够大时，二项分布近似于正态分布。

- 应用：如某炮兵阵地对敌人的防御地段进行100次射击，每次射击中炮弹的命中数是一个随机变量，其期望为2，方差为1.69，求在100次射击中有180颗到220颗炮弹命中目标的概率。

(4) 变量与随机变量有什么区别？

- 变量：描述确定性现象，取值固定唯一。
- 随机变量：描述随机现象，取值有多个，且每个取值都有一定的概率。

(5) 联合概率、边缘概率、条件概率

- 联合概率：两个事件共同发生的概率， $P(A, B)$
- 边缘概率：某个事件发生的概率，与其它事件无关， $P(A)$
- 条件概率：在事件 B 已经发生的条件下，事件 A 发生的概率， $P(A|B)$

(6) 先验概率、后验概率

- 先验概率：根据以往经验得到的概率，是“由因推果”问题中的“因”，不需要使用贝叶斯公式计算。
- 后验概率：得到结果后重新修正的概率，是“由果推因”问题中的“因”，需使用贝叶斯公式计算。
- 计算后验概率需要用到先验概率。

(7) 常见的概率分布

分布	分布列 p_k 或分布密度 $p(x)$	期望	方差
0-1 分布 $b(1, p)$	$p_k = p^k(1-p)^{1-k}, \quad k = 0, 1$	p	$p(1-p)$
二项分布 $b(n, p)$ n 重伯努里试验成功事件的次数 有放回抽 n 件，其中一种的件数	$p_k = \binom{n}{k} p^k(1-p)^{n-k}, \quad k = 0, 1, \dots, n$	np	$np(1-p)$
泊松分布 $P(\lambda)$ 单位时间的发生次数 单位面积 / 体积的数量	$p_k = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, \dots$	λ	λ
超几何分布 $h(n, N, M)$ 不放回抽 n 件，其中一种的件数	$p_k = \frac{\binom{M}{k} \binom{N-M}{n-k}}{\binom{N}{n}}, \quad k = 0, 1, \dots, r, \quad r = \min\{M, n\}$	$n \frac{M}{N}$	$\frac{nM(N-M)(N-n)}{N^2(N-1)}$
几何分布 $Ge(p)$ 事件首次出现时的试验次数	$p_k = (1-p)^{k-1} p, \quad k = 1, 2, \dots$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
负二项分布 $Nb(r, p)$ 事件第 r 次出现时的试验次数	$p_k = \binom{k-1}{r-1} (1-p)^{k-r} p^r, \quad k = r, r+1, \dots$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$
均匀分布 $U(a, b)$	$p(x) = \frac{1}{b-a}, \quad a < x < b$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
正态分布 $N(\mu, \sigma^2)$	$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}, \quad -\infty < x < \infty$	μ	σ^2
指数分布 $Exp(\lambda)$ 一般为寿命	$p(x) = \lambda e^{-\lambda x}, \quad x \geq 0$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$

补充几点：

- 0-1 分布又叫伯努利分布、两点分布。
- 泊松分布
 - λ : 单位时间 / 面积内随机事件的平均发生次数
 - 泊松分布和二项分布的关系: 当二项分布的 n 很大而 p 很小时, 泊松分布可作为二项分布的近似
 - 应用: 描述单位时间内随机事件发生的次数, 如: 一天内电路受电磁波干扰的次数
- 超几何分布 (不放回抽样): N 件产品中有 M 件不合格, 从 N 件产品中随机抽 n 件检查, 发现 k 件不合格品的概率

(8) 若干个高斯分布相加/相乘后得到的分布是什么

假设多个随机变量分别服从不同的高斯分布, 如果这些随机变量**彼此独立**, 那么这些随机变量的和也服从高斯分布, 乘积为高斯分布乘以常数。

https://blog.csdn.net/qg_41035283/article/details/121015712

(9) 期望和方差

- 期望: 随机变量的每个取值与其概率的乘积的累加和, 它描述了随机变量的集中特性。
- 方差: 随机变量的每个取值减去期望的平方与其概率的乘积的累加和, 它描述了随机变量的离散特性。
 - $D(X) = E((X - E(X))^2) = E(X^2) - E^2(X)$ (平方的期望-期望的平方)

(10) 协方差和相关系数

- 协方差: X, Y 的协方差等于每个 X 减去其平均值乘上每个 Y 减去其平均值的乘积的累加和的平均。

$$\begin{aligned} cov(X, Y) &= E[(X - E(X))(Y - E(Y))] \\ &= E[XY] - E[X]E[Y] \end{aligned}$$

- 意义: 协方差表示的是两个变量总体误差的期望, 当协方差为 0 时, 两者不线性相关; 协方差绝对值越大, 两者对彼此的影响越大 (>0 就是正相关, <0 就是负相关)
- $var(X + Y) = var(X) + var(Y) + 2cov(X, Y)$, var 指方差
- 协方差矩阵: n 维随机变量 $X = [X_1, X_2, \dots, X_n]^T$ 的协方差矩阵为 ($c_{ij} = cov(X_i, X_j)$)

$$C = (c_{ij})_{n \times n} = \begin{pmatrix} c_{11} & c_{12} & \dots & c_{1n} \\ c_{21} & c_{22} & \dots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \dots & c_{nn} \end{pmatrix}$$

- 相关系数: 用 X, Y 的协方差除以 X 的标准差和 Y 的标准差

$$\rho_{X,Y} = \frac{cov(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$$

- 意义：标准化的协方差，消除了两个变量量纲的影响，取值范围为 $[0, 1]$ 。

(11) 独立和不相关的区别

- 独立： $P(A|B) = P(A) \iff P(AB) = P(A)P(B)$
- 不相关： $cov(X, Y) = E[XY] - E[X]E[Y] = 0$
- 独立一定不相关，而不相关不一定独立。**不相关就是两者没有线性关系**，但是不排除其它关系存在；**独立就是互不相干没有关联**。

(12) 独立和互斥的关系

- 独立： $P(AB) = P(A)P(B)$
- 互斥： $A \cap B = \emptyset$
- 如果 $P(A) \neq 0, P(B) \neq 0$ ，则互斥不独立，独立不互斥。

(13) 古典概型和几何概型的区别

- 古典概型——有限等可能（有限个可能事件，且每个事件都是等可能概率事件）
- 几何概型——无限等可能

(14) 概率密度函数

- 连续型随机变量的取值有无穷多个实数，无法用分布列表示，所以用概率密度函数来表示。
- 概率密度函数不是概率，乘以区间长度微元后就表示概率的近似值。
- 概率密度函数在一段区间上的积分就是随机变量 X 在这段区间上取值的概率。

(15) 极大似然估计

- 一种**参数估计**的方法，它先确定模型，通过若干次实验，观察其结果，反推最有可能（最大概率）导致这样结果的参数值。
- 似然方程的解只是一个估计值，只有在样本数趋于无限多的时候，它才会接近于真实值。
- 步骤：
 1. 写出似然函数
 2. 对似然函数取对数，并整理
 3. 求导数
 4. 解似然方程

(16) 什么是假设和检验

- 假设检验：在总体分布函数未知的情况下，先对总体参数提出一个假设值，然后利用样本信息来判断这一假设是否成立。
- 基本思想：小概率事件在一次的实验中是不可能发生的。
- 两个假设：原假设（要检验的假设）、备选假设（拒绝原假设时的假设），他们是互补的。
- 两类错误
 - 第一类错误 (弃真错误)：原假设 H_0 为真，但是检验出的拒绝原假设，其概率为 α 。
 - 第二类错误 (存伪错误)：原假设 H_0 为假，但是检验出的接受原假设，其概率为 β 。
 - 两类错误是相互矛盾的，不能同时降低两种错误，因此一般在限制 α 的情况下，尽可能地降低 β 的值。
- 基本步骤
 1. 提出原假设和备选假设。
 2. 选取检验统计量。
 3. 给定显著性水平。
 4. 计算检验统计量的具体值，做出判断。

(17) 机器学习为什么要使用概率？

- 机器学习的是由**数据驱动**的方法，它的学习对象是数据，从数据出发提取数据特征抽象出数据模型又从数据中发现知识，最后回到数据的分析和预测中去。
- 机器学习的**算法设计**通常依赖于对数据的概率假设。
- 机器学习模型的训练和预测过程的**评价指标**——模型误差，其本身就是概率的形式。

(18) 不均匀硬币产生等概率

- 已知一随机发生器，产生 0 的概率是 p ，产生 1 的概率是 $1-p$ ，现在要你构造一个发生器，使得它构造 0 和 1 的概率均为 $1/2$ 。
 - 连续随机生成两次，可能的情况有
 - 00: pp
 - 01: $p(1-p)$
 - 10: $(1-p)p$
 - 11: $(1-p)(1-p)$
 - 所以 2 次 1 组，认为 01 表示 0，10 表示 1，等概率，其他情况放弃。
- 扩展到 3, 4, ..., n 同理，以 3 为例
 - 构造一个发生器，使得它构造 1, 2, 3 的概率均为 $1/3$ ：认为 001 表示 1，010 表示 2，100 表示 3，等概率，其他情况放弃。

(19) 伪随机数产生均匀分布

混合同余法，其中 m 是模长， a 是乘数， c 是增量， X_0 是初始值。

$$X_n = (aX_{n-1} + b) \% m / m$$

(20) 由均匀分布产生高斯分布

Box-Muller 算法，一共有两种形式，其中 U_1, U_2 是值域为 $(0, 1]$ 的均匀分布的随机数， Z_1, Z_2 是高斯分布的随机数。

$$Z_0 = R \cos(\Theta) = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$$

$$Z_1 = R \sin(\Theta) = \sqrt{-2 \ln U_1} \sin(2\pi U_2).$$

3 微积分

[保研面试/考研复试高等数学问题整理 - 知乎 \(zhihu.com\)](#)

格林公式 (Green formula)

若函数 $P(x, y), Q(x, y)$ 在闭区域 D 上连续，且有一阶的连续偏导数，则有

$$\iint_D \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dx dy = \oint_L P dx + Q dy, \text{ 这里 } L \text{ 为闭区域的边界曲线并取正向。}$$

高斯公式 (Gauss formula)

设空间闭区域 V 由分片光滑的双侧封闭曲面 S 围成，若函数 P, Q, R 在 V 上连续，且有一阶的连续偏导数，则 $\iiint_V \left(\frac{\partial P}{\partial x} + \frac{\partial Q}{\partial y} + \frac{\partial R}{\partial z} \right) dx dy dz = \iiint_S P dy dz + Q dx dz + R dx dy,$


其中 S 取外侧。

斯托克斯公式 (Stokes formula)

设光滑曲面 S 的边界 L 是按段光滑的连续曲线，若函数 P, Q, R 在 S (连同 L) 上连续，且有一阶的连续偏导数，则

$$\oint_L P dx + Q dy + R dz = \iint_S \left(\frac{\partial R}{\partial y} - \frac{\partial Q}{\partial z} \right) dy dz + \left(\frac{\partial P}{\partial z} - \frac{\partial R}{\partial x} \right) dz dx + \left(\frac{\partial Q}{\partial x} - \frac{\partial P}{\partial y} \right) dx dy$$

，其中 S 的侧与 L 的方向按右手法则确定。



4 离散数学

(1) 自反、对称、传递

- 假设集合A, 以及基于A上的关系R
 - 自反: 如果a是A的元素, 那么 $\langle a, a \rangle$ 是R的元素
 - 对称: 如果 $\langle a, b \rangle$ 是R的元素, 那么 $\langle b, a \rangle$ 是R的元素
 - 传递: 如果 $\langle a, b \rangle, \langle b, c \rangle$ 是R的元素, 那么 $\langle a, c \rangle$ 是R的元素

(2) 对称传递能不能推出自反性?

不能

(3) 自反性存在有什么意义?

自反性是等价关系的基石。

(4) 等价关系和等价类

自反+对称+传递

(5) 偏序关系

自反+反对称+传递